

沈阳航空航天大学

《模式识别》技术分析报告

题目：基于跨模态学习的动作识别

院（系）： 人工智能学院

专 业： 物联网工程

班 级： 物联网2202

学 号： 223428010210

姓 名： 陈梓欣

指导教师： 刘翠微

目录

概要.....1

1 研究背景与意义.....1

2 技术发展现状2

 2.1 模态类型与挑战.....2

 2.2 多模态融合 vs 跨模态学习3

 2.3 技术框架与典型方法4

 2.4 国内研究动态5

3 典型应用场景5

 3.1 智能安防监控5

 3.2 医疗康复辅助6

 3.3 体育训练与分析.....7

 3.4 智能家居与人机交互8

4 未来发展趋势8

 4.1 模态大模型驱动.....8

 4.2 时空语义理解深化.....9

 4.3 边缘计算与低功耗部署.....9

 4.4 可靠性、可解释性与隐私保护.....10

5 社会影响与伦理分析.....10

 5.1 社会福祉提升10

 5.2 文化与教育价值.....11

 5.3 伦理与隐私挑战.....11

 5.4 监管与法律视角.....11

6 结论11

参考文献12

概要

随着人工智能、视频理解与传感器技术的迅猛发展,动作识别正朝向多模态、跨模态融合方向演进。相比传统单模态方法,跨模态学习(Cross-Modal Learning)能够利用视觉、骨骼、深度、语音、惯性传感器等多源数据互补优势,从而提升识别精度、鲁棒性和适用性。本文首先分析动作识别所面临的问题与背景,然后梳理跨模态动作识别技术的发展现状、典型应用场景、未来趋势与社会影响,最后总结研究挑战与发展建议。

1 研究背景与意义

动作识别(Action Recognition)是计算机视觉与人体行为理解的重要分支,其目标是从视频、传感器或其他信号中识别人的动作类型,如“走路”“跳跃”“挥手”等。随着智能监控、体育分析、医疗康复、智能家居等应用需求的增长,动作识别技术的意义日益凸显。

传统动作识别方法多基于单一模态(如 RGB 视频、骨骼序列或深度图像),但在复杂环境(如遮挡、视角变化、背景杂乱)下往往表现欠佳。此外,单一模态往往难以全面捕捉动作的语义、意图与上下文信息。

跨模态学习提供了一条新的思路:通过融合不同模态(视频帧、骨骼关节、深度图、惯性传感器、语音或文本说明等)数据,建立统一的特征或语义空间,使模型能够跨模态理解和识别动作,从而提升识别效率和准确率。

对于“基于跨模态学习的动作识别”这一方向而言,不仅具有研究价值,也具有实际应用意义,如智能监控中结合视频与麦克风信号识别异常行为、可穿戴设备结合加速度计与视频数据监测老年人跌倒等,如图 1 所示。




图 1 监测老年人跌倒

2 技术发展现状

2.1 模态类型与挑战

当前，动作识别所用的模态主要包括以下几类：

1. 视频 RGB / 深度图像 (RGB / Depth):

RGB 视频提供丰富的空间与时间特征，可捕捉动作的细节纹理、颜色及背景信息；深度图像能够提供三维结构信息，有利于动作姿态的解析。然而，视频模态对环境条件高度敏感，易受摄像机视角、遮挡、光照变化以及背景复杂度的影响，导致动作特征提取困难。此外，高分辨率视频处理计算量大，实时性要求较高时存在性能瓶颈。

2. 骨骼关节点数据 (Skeleton):

骨骼模态通过关节点位置和骨架连接关系抽象人体姿态变化，对遮挡和背景噪声具有较强鲁棒性，同时数据量小，便于实时处理与动作建模。但其缺乏纹理、表面信息及环境上下文，容易在相似动作（如挥手与招手）区分上出现困难，且对关节点检测精度依赖较大。

3. 惯性传感器 (IMU / 加速度计 / 陀螺仪):

惯性模态通过可穿戴设备采集加速度、角速度等信息，可在移动场景中捕捉人体运动轨迹，适用于室外或非固定环境下的动作识别。然而，惯性数据通常缺少空间语义信息，动作模式解释困难，易受传感器噪声和设备佩戴位置变化影响，且跨个体的泛化能力较弱。

4. 语音、文本或语义说明 (Audio / Language / Semantic):

语音或文本模态可为动作提供语义层面的补充，例如描述动作目的、情境或动作类别，有助于动作理解和场景分析。但这类模态与视觉模态在时间上难以严格同步，跨模态对齐存在挑战，同时语义表达存在模糊性，对模型理解能力要求较高。

综上，各模态各有优势与局限，因此单模态识别方法在复杂场景下难以兼顾准确性与鲁棒性。近年来，多模态融合和跨模态学习成为研究热点。中华期刊《信号处理》中指出，“大多数双流网络缺乏对多模态信息的充分利用，容易造成网络冗余及相似动作误判”，表明有效的模态整合策略对于提升识别性能至关重要。

2.2 多模态融合 vs 跨模态学习

1. 多模态融合 (Multimodal Fusion)

多模态融合强调在特征级或决策级整合来自不同模态的数据, 以提升动作识别的准确性和鲁棒性。常见策略包括:

- 特征级融合 (Feature-level Fusion): 将各模态的特征向量在网络内部进行拼接或加权组合, 形成统一表示, 用于分类或预测。
- 决策级融合 (Decision-level Fusion): 对各模态独立训练的模型输出结果进行融合, 如投票、加权平均或置信度融合, 从而得到最终动作类别。

典型应用包括 RGB + 光流 + 骨骼数据的融合, 实现视觉与运动信息的协同建模, 提高对相似动作的区分能力。

2. 跨模态学习 (Cross-Modal Learning)

跨模态学习关注不同模态之间的对齐、迁移和表示共享, 能够在部分模态缺失的情况下仍实现准确识别。关键方法包括:

- 模态对齐 (Modality Alignment): 通过映射到统一特征空间, 使不同模态的相同动作语义保持一致, 例如将 IMU 轨迹映射到视觉特征空间。
- 模态迁移 (Modality Transfer): 将一种模态的知识迁移到另一模态, 例如 IMU 数据知识迁移到 RGB 视频识别中, 以补充缺失的视觉信息。
- 跨模态对比学习 (Cross-Modal Contrastive Learning): 利用语言-视觉对比学习 (如 CLIP 模型) 进行预训练, 使模型在多模态场景下学习共享表示, 增强动作语义理解能力。

最新研究表明, 基于大模型的跨模态学习方法正在推动动作识别从单纯的特征匹配向语义理解方向发展, 实现对复杂动作及其语境的准确识别。多模态融合与跨模态学习流程图如图 2 所示。




图 2 多模态融合与跨模态学习流程图

2.3 技术框架与典型方法

典型的跨模态动作识别框架通常包括以下核心模块：

1. 模态特征提取（Modality Feature Extraction）

对每种模态数据使用专门的网络进行特征提取，如：

- RGB / 视频帧：CNN、3D-CNN、时空注意力网络（TSN、I3D）
- 骨骼关节数据：图卷积网络（GCN）、序列模型（LSTM、GRU）
- 惯性传感器（IMU）：一维卷积或循环网络提取时间序列特征
- 语音/文本/语义：BERT、Transformer 或声学特征提取器

目标是将原始模态数据映射为统一的高维特征表示，便于后续对齐和融合。

2. 模态对齐 / 投影（Modality Alignment / Projection）

不同模态的特征往往分布在不同空间，需要对齐或投影到共享特征空间，实现跨模态语义一致性。

技术手段包括对比学习、变换编码器、注意力机制等。

对齐后的特征能够支持缺模态情况下的识别或模态间知识迁移。

3. 模态融合 / 对抗（Modality Fusion / Adversarial Learning）

融合方式：

- 特征级融合：将多模态特征在向量层面拼接或加权组合
- 决策级融合：对各模态独立预测结果进行加权或投票

对抗学习：

- 通过模态间对抗训练减小冗余，提高鲁棒性

- 增强模型在复杂场景下对相似动作的区分能力

4. 动作分类（Action Classification）

将融合后的多模态特征输入分类器进行动作预测，常用方法包括 Softmax 分类、SVM 或深度分类网络，即在大模型框架下，也可输出动作类别概率或动作嵌入表示，支持检索与下游任务。

近年来，研究中出现了多种创新方法：

低层次跨模态交互：如 MEACI-Net，在压缩视频中进行 RGB 与运动模态的低层次特征交互，实现信息互补，减少冗余。

多模态大模型（Multimodal Foundation Models）：融合视觉、语言等多模态信息，通过预训练模型（如 CLIP）获得跨模态通用特征，增强动作语义理解能力。

注意力机制与图网络结合：利用注意力动态选择模态信息，结合骨骼或空间结构建模，进一步提升识别精度。

2.4 国内研究动态

近年来，国内跨模态动作识别研究取得了显著进展。各大高校和科研机构积极探索多模态信息融合、跨模态表示学习及模态可靠性偏置等关键问题。

例如，成都某高校的研究团队针对多模态动作识别中不同模态可靠性差异提出改进方法，在提高识别准确率和鲁棒性方面取得了阶段性成果。同时，国内期刊如《自动化学报》等陆续发表相关研究，涉及基于视觉、骨骼和惯性传感器的跨模态融合模型、低层次特征交互策略以及大模型驱动的视频行为识别方法。

这表明中文学术界已逐渐形成自主创新能力，推动跨模态动作识别技术向实用化、智能化方向发展，为智能监控、运动分析及人机交互等应用提供了理论和技术支撑。

3 典型应用场景

3.1 智能安防监控

在公共安全领域，跨模态动作识别技术可有效提升异常行为检测能力。通过融合视频、音频以及环境传感器数据，系统能够实时识别“挣扎”“跌倒”“打斗”

等危险或异常动作。例如，监控摄像头捕捉的视频与麦克风采集的声学信号结合，可辅助判定群体冲突或突发事件，并及时触发警报。跨模态融合能够缓解单一视频模态在遮挡、低光照或复杂背景下的识别局限性，提高安防监控的精度和鲁棒性，支持城市公共场所及关键设施的智能安全管理。如图 3 所示




图 3 智能安防监控

3.2 医疗康复辅助

在康复训练场景中，动作识别技术通过骨骼关节点与 IMU 传感器数据，对患者运动进行精细化监控和评估。系统能够识别动作执行的规范性、角度偏差及节奏变化，并通过跨模态融合整合视觉和惯性信息，实现对动作细节和训练环境的全面理解，从而为康复师提供科学指导，并通过反馈机制辅助患者矫正训练动作，提高康复效率和安全性。如图 4 所示。



图 4 医疗康复辅助

3.3 体育训练与分析

在体育训练和竞技分析中，跨模态动作识别可整合视频、惯性传感器数据以及语音解说或战术指令，实现运动动作质量评估、战术执行分析及运动员表现优化。通过跨模态特征对齐和融合，系统不仅能够提高动作识别准确率，还可为教练提供动作执行的量化指标和语义化解释，有助于战术分析、技术改进及运动员个性化训练方案制定。如图 5 所示。




图 5 体育训练与分析

3.4 智能家居与人机交互

在智能家居场景中，动作识别系统通过视频、语音和姿态传感器捕捉用户行为，实现环境响应自动化。例如，挥手或招手可触发灯光开关，跌倒动作可触发紧急提醒。跨模态融合增强了系统对动作环境和用户意图的理解能力，使识别更加准确，同时提高交互体验的自然性与安全性，为智能家居、老年人看护及辅助生活设备提供了技术保障。如图 6 所示。



图 6 智能家居与人机交互

4 未来发展趋势

4.1 模态大模型驱动

未来跨模态动作识别技术将逐步借鉴视觉 - 语言大模型的设计理念，实现统一的多模态表示学习。通过大规模预训练模型，系统可在“少样本”或“无标注”场景下进行动作识别，降低对昂贵标注数据的依赖。例如，提出的“Cross-Modal Federated Human Activity Recognition”探索了跨模态联邦学习任务，在保证数据隐私的同时，实现分布式、多源模态信息共享与联合建模。这种模态大模型驱动的方法有望提升动作识别的泛化能力和语义理解水平，同时支持多领域应用。

4.2 时空语义理解深化

未来动作识别不仅关注“做了什么”，还将深入理解“为什么做”，包括动作意图、情境语义和上下文依赖。跨模态学习可引入语义文本说明、语言描述以及历史动作预测，将视觉、骨骼和惯性等低层特征与高层语义信息对齐，实现动作理解的语义化与时空化。这将推动智能监控、运动分析和人机交互从单纯识别向预测、决策和行为理解升级，提高系统对复杂环境和连续动作的处理能力。如图 7 所示。




图 7 时空语义理解深化

4.3 边缘计算与低功耗部署

随着智能可穿戴设备、无人机和智能摄像头的普及，跨模态动作识别模型需要在边缘端实现轻量化和实时化。未来研究将聚焦于低功耗神经网络设计、模型压缩、知识蒸馏以及分布式计算策略，以兼顾计算效率、响应速度和隐私保护。同时，边缘部署有助于减少数据上传频次，降低网络负载，并增强用户敏感信息的安全性，为移动健康、家庭智能监控等场景提供可行技术方案。如图 8 所示。




图 8 边缘计算与低功耗部署

4.4 可靠性、可解释性与隐私保护

跨模态融合带来的数据丰富性虽然提升了识别性能，但也引入了模态缺失、数据偏倚及隐私泄露等风险。未来研究将更加关注模型可靠性评估、可解释机制设计以及隐私保护策略。例如，通过对模态贡献度进行可解释分析、引入对抗训练减少偏倚、以及采用联邦学习和数据匿名化方法保护用户隐私。可靠、可解释且合规的跨模态动作识别系统将成为推动实际应用和社会信任的重要保障。

5 社会影响与伦理分析

5.1 社会福祉提升

跨模态动作识别技术在社会福祉领域具有重要应用价值。通过融合视频、骨骼、惯性传感器及语音等多模态信息，系统能够实时监测老年人跌倒、儿童异常行为及残障人士的日常动作，为家庭、社区及养老机构提供智能预警服务。此外，公共安全事件的快速检测与响应能力也可显著增强，如在人群密集区域发现争执、打斗或突发事件时及时报警，从而提升社会整体安全水平和健康保障。跨模态技术的广泛应用有望降低意外伤害率，改善弱势群体生活质量。

5.2 文化与教育价值

在教育与文化领域，跨模态动作识别技术能够辅助教学、评估学习效果及推动传统文化创新。例如，在体育教育中，系统可对学生动作进行量化分析，评估动作标准性和训练效果；在舞蹈或武术教学中，可通过骨骼与视频数据分析动作精度，辅助教师指导并提供个性化反馈。此外，该技术还可用于传统文化传承，通过对武术、民族舞蹈等动作进行动作识别与数字化记录，实现文化内容的保存、分析与创新，促进教育现代化与文化传播。

5.3 伦理与隐私挑战

跨模态学习系统依赖大量视频、声音、IMU 及其他传感器数据，这带来了隐私泄露的潜在风险。例如，持续监控可能涉及个人日常行为、位置及生理信息的收集；算法在少数群体动作识别精度上的不足，也可能导致偏倚和公平性问题。为应对这些挑战，系统设计应遵循算法透明性、可解释性及数据最小化原则，确保用户知情和数据安全，同时建立公平评估机制，减少算法偏差带来的不利影响。

5.4 监管与法律视角

在公共监控、智能家居、医疗康复等应用场景中，跨模态动作识别系统必须遵循《个人信息保护法》《网络安全法》等法律法规要求。系统设计应内置隐私保护机制，如数据匿名化、加密存储及访问控制，同时设置防止滥用的技术手段与使用规范。此外，监管机构可制定标准化评估流程，对系统的安全性、隐私合规性和算法公平性进行监督，以保障技术应用在合法、合规和安全的框架下运行，从而实现技术进步与社会伦理的平衡。

6 结论

基于前述分析，跨模态动作识别技术正处于快速发展与应用拓展的阶段。多模态融合和跨模态学习通过整合视频、骨骼、惯性传感器及语音文本等信息，有效克服了单模态识别在遮挡、光照、模态缺失及语义理解方面的局限性。国内外研究表明，基于特征提取、模态对齐、融合与分类的完整技术框架，结合低层次

交互机制与大模型预训练，可显著提升动作识别的精度与鲁棒性。

在应用层面，跨模态动作识别已广泛渗透至智能安防、医疗康复、体育训练及智能家居等场景，为社会安全、健康管理、教育培训及文化传承提供了技术支持。同时，该技术发展也带来了隐私保护、算法偏倚和伦理合规等挑战，需要通过可解释性模型、数据最小化、联邦学习及法律规范来加以应对。

未来，随着模态大模型、时空语义理解和边缘计算的发展，跨模态动作识别将实现少样本、实时化、低功耗和高可靠性的目标，推动技术从实验室走向智能化、可落地的实际应用，形成安全、便捷、智能的人机交互与行为理解新模式。

参考文献

- [1] 刘罡,李小雨,吴烨,等. 基于跨模态协同感知的双流融合动作识别模型[J/O L].电子测量技术,1-11[2025-11-13].<https://link.cnki.net/urlid/11.2175.tn.20250618.1323.003>.
- [2] 魏冉.基于小样本的视频动作识别方法研究[D].南京林业大学,2025.DOI:10.27242/d.cnki.gnjlu.2025.000529.
- [3] 盛振涛,陈雁翔,齐国君. 面向多模态自监督特征融合的音视频对抗对比学习[J].中国图象图形学报,2023,28(01):317-332.
- [4] 汪雯.基于深度学习的人体动作分析与识别方法研究[D].电子科技大学,2021.DOI:10.27005/d.cnki.gdzku.2021.005026.
- [5] 丁川,崔爱浩,齐林,等. 基于多模态的人体动作识别研究[J].人工智能,2021,(01):50-58.DOI:10.16453/j.cnki.ISSN2096-5036.2021.01.005.
- [6] 马泽宇.跨模态视频分类研究[D].电子科技大学,2020.DOI:10.27005/d.cnki.gdzku.2020.001430.
- [9] 韩敏捷. 基于深度学习框架的多模态动作识别[J].计算机与现代化,2017,(07):48-52.